

MACIERZ ORTOGONALNA

Jeśli macierz $\mathbf{Q}_{m \times n}$ ($m \geq n$) ma **kolumny wzajemnie ortogonalne**, to

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{D}_n,$$

gdzie \mathbf{D}_n jest macierzą diagonalną o wymiarowości n .

Jeśli kolumny \mathbf{Q} są, dodatkowo, wektorami ortonormalnymi, to

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I}_n$$

Macierz **kwadratową** \mathbf{Q} nazywamy **macierzą ortogonalną**, jeśli

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{I},$$

tzn. \mathbf{Q} to macierz kwadratowa, której kolumny są wektorami ortonormalnymi.

Formalnie definicja powyższa określa **macierz ortonormalną**, ale *podana definicja przyjęła się w literaturze*.

MACIERZ ORTOGONALNA 2

Z definicji $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}$ wynika bezpośrednio, że

$$\mathbf{Q}^T = \mathbf{Q}^{-1},$$

skąd dalej

$$\mathbf{Q}^T \mathbf{Q} = \mathbf{Q} \mathbf{Q}^T = \mathbf{I},$$

tzn. w macierzy ortogonalnej **kolumny są wektorami wzajemnie ortonormalnymi** oraz **wiersze są wektorami wzajemnie ortonormalnymi**.

Lemat

Jeśli $\mathbf{Q}_{m \times n}$ – macierz o kolumnach będących wektorami ortonormalnymi, to

$$\|\mathbf{Q}\mathbf{x}\|_2 = \|\mathbf{x}\|_2.$$

Dowód. Z definicji normy drugiej i z własności $\mathbf{Q}^T \mathbf{Q} = \mathbf{I}_n$ wynika

$$\forall \mathbf{x} \quad \|\mathbf{Q}\mathbf{x}\|_2 = \sqrt{\mathbf{x}^T \mathbf{Q}^T \mathbf{Q} \mathbf{x}} = \sqrt{\mathbf{x}^T \mathbf{x}} = \|\mathbf{x}\|_2.$$

Wniosek. Dla macierzy ortogonalnej obowiązuje:

$$\|\mathbf{Q}\mathbf{x}\|_2 = \|\mathbf{x}\|_2, \quad \|\mathbf{Q}^T \mathbf{x}\|_2 = \|\mathbf{x}\|_2.$$

ROZKŁAD QR (ortogonalno-trójkątny)

Twierdzenie. Każdą macierz $\mathbf{A}_{m \times n}$, ($m \geq n$) o liniowo niezależnych kolumnach (tj. o pełnym rzędzie równym n) można przedstawić w postaci następujących rozkładów ortogonalno- trójkątnych:

1. Rozkład QR wąski (ekonomiczny) nieunormowany:

$$\mathbf{A}_{m \times n} = \bar{\mathbf{Q}}_{m \times n} \bar{\mathbf{R}}_{n \times n},$$

gdzie $\bar{\mathbf{Q}}_{m \times n}$ jest macierzą o kolumnach wzajemnie ortogonalnych (nie ortonormalnych), a $\bar{\mathbf{R}}_{n \times n}$ trójkątną górną z jedynkami na diagonalu;

2. Rozkład QR wąski (ekonomiczny):

$$\mathbf{A}_{m \times n} = \mathbf{Q}_{m \times n} \mathbf{R}_{n \times n},$$

gdzie $\mathbf{Q}_{m \times n}$ jest macierzą o kolumnach ortonormalnych, a $\mathbf{R}_{n \times n}$ trójkątną górną z dodatnimi elementami na diagonalu;

3. Rozkład QR:

$$\mathbf{A}_{m \times n} = \mathbf{Q}_{m \times m} \begin{bmatrix} \mathbf{R}_{n \times n} \\ \mathbf{0} \end{bmatrix}_{m \times n} = \begin{bmatrix} \mathbf{Q}_{m \times n} & \mathbf{Q}_{m \times (m-n)}^2 \end{bmatrix} \begin{bmatrix} \mathbf{R}_{n \times n} \\ \mathbf{0} \end{bmatrix}_{m \times n},$$

gdzie $\mathbf{Q}_{m \times m}$ jest macierzą ortogonalną.

ROZKŁAD QR (ortogonalno-trójkątny) 2

Dowód - przez konstrukcję rozkładów.

1. Niech $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$. Zortogonalizujemy kolumny \mathbf{a}_i macierzy \mathbf{A} standardowym algorytmem Grama-Schmidta, oznaczając przez $\bar{\mathbf{q}}_i$ wektory zortogonalizowane:

$$\bar{\mathbf{q}}_1 = \mathbf{a}_1, \quad \bar{r}_{11} \triangleq 1,$$

$$\bar{\mathbf{q}}_2 = \mathbf{a}_2 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_2}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 = \mathbf{a}_2 - \bar{r}_{12} \bar{\mathbf{q}}_1, \quad \bar{r}_{22} \triangleq 1,$$

$$\bar{\mathbf{q}}_i = \mathbf{a}_i - \sum_{j=1}^{i-1} \frac{\bar{\mathbf{q}}_j^T \mathbf{a}_i}{\bar{\mathbf{q}}_j^T \bar{\mathbf{q}}_j} \bar{\mathbf{q}}_j = \mathbf{a}_i - \sum_{j=1}^{i-1} \bar{r}_{ji} \bar{\mathbf{q}}_j, \quad \bar{r}_{ii} \triangleq 1, \quad i = 3, \dots, n.$$

Równania powyższe można przepisać w postaci:

$$\mathbf{a}_1 = \bar{r}_{11} \bar{\mathbf{q}}_1, \quad \bar{r}_{11} \triangleq 1,$$

$$\mathbf{a}_2 = \bar{r}_{12} \bar{\mathbf{q}}_1 + \bar{r}_{22} \bar{\mathbf{q}}_2 = \sum_{j=1}^2 \bar{r}_{j2} \bar{\mathbf{q}}_j, \quad \bar{r}_{12} = \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_2}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1}, \quad \bar{r}_{22} \triangleq 1,$$

$$\mathbf{a}_i = \sum_{j=1}^{i-1} \bar{r}_{ji} \bar{\mathbf{q}}_j + \bar{r}_{ii} \bar{\mathbf{q}}_i = \sum_{j=1}^i \bar{r}_{ji} \bar{\mathbf{q}}_j, \quad \bar{r}_{ji} = \frac{\bar{\mathbf{q}}_j^T \mathbf{a}_i}{\bar{\mathbf{q}}_j^T \bar{\mathbf{q}}_j}, \quad \bar{r}_{ii} \triangleq 1, \quad i = 3, \dots, n.$$

ROZKŁAD QR (ortogonalno-trójkątny) 3

Wykorzystamy ogólną własność iloczynu macierzy:

i-ta kolumna \mathbf{a}_i macierzy iloczynowej $\mathbf{A} = \mathbf{BC}$ jest kombinacją liniową kolumn pierwszej macierzy iloczynu \mathbf{B} , ze współczynnikami będącymi elementami i-tej kolumny drugiej macierzy iloczynu \mathbf{C} :

$$\mathbf{a}_i = \mathbf{B}\mathbf{c}_i = [\mathbf{b}_1 \ \mathbf{b}_2 \ \cdots \ \mathbf{b}_n] \begin{bmatrix} c_{1i} \\ c_{2i} \\ \vdots \\ c_{ni} \end{bmatrix} = \sum_{j=1}^n \mathbf{b}_j c_{ji}$$

Stosując tę własność do $\mathbf{a}_i = \sum_{j=1}^i \bar{\mathbf{q}}_j \bar{r}_{ji}$ można zapisać:

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_n] = [\bar{\mathbf{q}}_1, \dots, \bar{\mathbf{q}}_n] \begin{bmatrix} 1 & \bar{r}_{12} & \cdots & \bar{r}_{1n} \\ 0 & 1 & \cdots & \bar{r}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = \bar{\mathbf{Q}}\bar{\mathbf{R}},$$

gdzie macierz $\bar{\mathbf{Q}}_{m \times n} = [\bar{\mathbf{q}}_1, \dots, \bar{\mathbf{q}}_n]$ ma kolumny ortogonalne (nie ortonormalne), a macierz $\bar{\mathbf{R}}_{n \times n}$ jest trójkątna górna z jedynkami na diagonalu, co kończy dowód 1.

ROZKŁAD QR (ortogonalno-trójkątny) 4

2. Jeśli przeprowadzimy normalizację kolumn macierzy \bar{Q} :

$$Q = \left[\frac{\bar{q}_1}{\|\bar{q}_1\|}, \frac{\bar{q}_2}{\|\bar{q}_2\|}, \dots, \frac{\bar{q}_n}{\|\bar{q}_n\|} \right]$$

oraz dokonamy przekształcenia

$$R = N\bar{R},$$

gdzie

$$N = \begin{bmatrix} \|\bar{q}_1\| & 0 & \dots & 0 \\ 0 & \|\bar{q}_2\| & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \|\bar{q}_n\| \end{bmatrix},$$

to uzyskamy rozkład QR wąski

$$A_{m \times n} = Q_{m \times n} R_{n \times n},$$

gdzie $Q_{m \times n}$ ma kolumny ortonormalne, co kończy dowód tezy 2.

ROZKŁAD QR (ortogonalno-trójkątny) 5

3. Jeśli

- macierz $\mathbf{Q}_{m \times n}$ uzupełnimy do macierzy kwadratowej ortogonalnej $\mathbf{Q}_{m \times m}$ przez dodanie $m-n$ kolumn – dowolnych, ale ortonormalnych wzajemnie i z kolumnami macierzy $\mathbf{Q}_{m \times n}$,
- macierz $\mathbf{R}_{n \times n}$ uzupełnimy zerami do wymiaru $m \times n$,

to uzyskamy rozkład QR (pełny):

$$\mathbf{A}_{m \times n} = \begin{bmatrix} \mathbf{Q}_{m \times n} & \mathbf{Q}_{m \times (m-n)}^2 \end{bmatrix} \begin{bmatrix} \mathbf{R}_{n \times n} \\ \mathbf{0} \end{bmatrix}_{m \times n} = \mathbf{Q}_{m \times m} \begin{bmatrix} \mathbf{R}_{n \times n} \\ \mathbf{0} \end{bmatrix}_{m \times n},$$

co kończy dowód Twierdzenia.

W ogólności, *rozkład QR istnieje dla każdej macierzy $\mathbf{A}_{m \times n}$, $m \geq n$, (również o rzędzie $k < n$).*

ROZKŁAD QR (ortogonalno-trójkątny) 6

Numerycznego obliczenia rozkładu QR macierzy można dokonywać:

1. Dla macierzy o pełnym rzędzie, metodą ortogonalizacji Grama-Schmidta:

- 1a. rozkład QR wąski nieunormowany,
- 1b. po normalizacji rozkład QR wąski,
- 1c. który można dalej rozszerzyć do rozkładu QR pełnego: uzupełniamy macierz $\mathbf{A}_{m \times n}$ do macierzy kwadratowej

$$\mathbf{A}_{m \times m} = [\mathbf{A}_{m \times n} \mathbf{A}_{m \times (m-n)}],$$

przez dodanie jakichkolwiek $m - n$ kolumn tworzących uzupełnienie $\mathbf{A}_{m \times (m-n)}$ liniowo niezależnych z kolumnami macierzy $\mathbf{A}_{m \times n}$ (i względem siebie),

i kontynuujemy również dla nich, kolejno, ortogonalizację Grama-Schmidta. Rozszerzamy \mathbf{R} o zera.

Z reguły stosujemy tzw. *zmodyfikowany algorytm Grama-Schmidta*, który ma lepsze własności numeryczne.

ROZKŁAD QR (ortogonalno-trójkątny) 7

Dla macierzy o **niepełnym (dowolnym) rzędzie** można odpowiednio rozszerzyć algorytm Grama-Schmidta;

ale zalecane jest stosowanie jednej z metod podanych poniżej:

2. **metodą odbić Householdera** – dostajemy od razu rozkład QR (pełny), w razie potrzeby rozkład wąski uzyskujemy przez usunięcie ostatnich $m - n$ kolumn macierzy $Q_{m \times m}$ i $m - n$ ostatnich wierszy macierzy $R_{m \times n}$;
3. **metodą obrotów Givensa** – dostajemy od razu rozkład QR (pełny), podobnie jak przy metodzie odbić Householdera. Metoda zalecana *dla macierzy rzadkich*.

ROZKŁAD QR – Przykład

Dokonyamy rozkładu QR macierzy

$$\text{a) } \mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2] = \begin{bmatrix} 1 & 1 \\ 2 & -1 \\ -2 & 4 \end{bmatrix}$$

Ortogonalizacja:

$$\bar{\mathbf{q}}_1 = \mathbf{a}_1 = [1 \ 2 \ -2]^T,$$

$$\bar{\mathbf{q}}_2 = \mathbf{a}_2 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_2}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 = \mathbf{a}_2 - \bar{r}_{12} \bar{\mathbf{q}}_1 = \begin{bmatrix} 1 \\ -1 \\ 4 \end{bmatrix} - \frac{-9}{9} \begin{bmatrix} 1 \\ 2 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}.$$

Stąd dostajemy rozkład wąski (nieunormowany):

$$\bar{\mathbf{Q}}_{\mathbf{A}} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ -2 & 2 \end{bmatrix}, \quad \bar{\mathbf{R}}_{\mathbf{A}} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}.$$

Normując kolumny macierzy $\bar{\mathbf{Q}}_{\mathbf{A}}$ dostajemy rozkład wąski:

$$\mathbf{N} = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}, \quad \mathbf{Q}_{\mathbf{A}} = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} \\ -\frac{2}{3} & \frac{2}{3} \end{bmatrix}, \quad \mathbf{R}_{\mathbf{A}} = \mathbf{N} \bar{\mathbf{R}}_{\mathbf{A}} = \begin{bmatrix} 3 & -3 \\ 0 & 3 \end{bmatrix}.$$

ROZKŁAD QR – Przykład c.d.

b)

$$\mathbf{B} = [\mathbf{a}_1 \ \mathbf{a}_2 \ \mathbf{a}_3] = \begin{bmatrix} 1 & 1 & 9 \\ 2 & -1 & 0 \\ -2 & 4 & 0 \end{bmatrix} \quad \left(\bar{\mathbf{Q}}_{\mathbf{A}} \bar{\mathbf{R}}_{\mathbf{A}} = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ -2 & 2 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \right)$$

$\mathbf{B} = [\mathbf{A} \ \mathbf{a}_3]$, stąd wystarczy dodać ortogonalizację trzeciej kolumny:

$$\bar{\mathbf{q}}_3 = \mathbf{a}_3 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_3}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 - \frac{\bar{\mathbf{q}}_2^T \mathbf{a}_3}{\bar{\mathbf{q}}_2^T \bar{\mathbf{q}}_2} \bar{\mathbf{q}}_2 = \mathbf{a}_3 - \bar{r}_{13} \bar{\mathbf{q}}_1 - \bar{r}_{23} \bar{\mathbf{q}}_2 = \begin{bmatrix} 9 \\ 0 \\ 0 \end{bmatrix} - \frac{9}{9} \begin{bmatrix} 1 \\ 2 \\ -2 \end{bmatrix} - \frac{18}{9} \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 4 \\ -4 \\ -2 \end{bmatrix}$$

Dostajemy rozkład nieunormowany

$$\bar{\mathbf{Q}}_{\mathbf{B}} = \begin{bmatrix} 1 & 2 & 4 \\ 2 & 1 & -4 \\ -2 & 2 & -2 \end{bmatrix}, \quad \bar{\mathbf{R}}_{\mathbf{B}} = \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix}.$$

Normując kolumny macierzy $\bar{\mathbf{Q}}$ dostajemy:

$$\mathbf{N} = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 6 \end{bmatrix}, \quad \mathbf{Q}_{\mathbf{B}} = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} & -\frac{2}{3} \\ -\frac{2}{3} & \frac{2}{3} & -\frac{1}{3} \end{bmatrix}, \quad \mathbf{R}_{\mathbf{B}} = \mathbf{N} \bar{\mathbf{R}}_{\mathbf{B}} = \begin{bmatrix} 3 & -3 & 3 \\ 0 & 3 & 6 \\ 0 & 0 & 6 \end{bmatrix}.$$

ALGORYTMY Grama-Schmidta CGS i MGS

Klasyczny algorytm Grama-Schmidta (CGS, nienormowany) ortogonalizuje kolumny macierzy **kolejno, względem wszystkich już zortogonalizowanych**:

$$\bar{\mathbf{q}}_1 = \mathbf{a}_1 \Rightarrow \bar{\mathbf{q}}_2 = \mathbf{a}_2 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_2}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 \Rightarrow \bar{\mathbf{q}}_3 = \mathbf{a}_3 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_3}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 - \frac{\bar{\mathbf{q}}_2^T \mathbf{a}_3}{\bar{\mathbf{q}}_2^T \bar{\mathbf{q}}_2} \bar{\mathbf{q}}_2 \Rightarrow \text{itd.} \dots$$

Zmodyfikowany algorytm Grama Schmidta (MGS, nienormowany) **ortogonalizuje wobec ostatniej zortogonalizowanej kolumny wszystkie następne kolumny**:

$$\bar{\mathbf{q}}_1 = \mathbf{a}_1$$

$$\bar{\mathbf{q}}_2 = \mathbf{a}_2 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_2}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1$$

$$\mathbf{a}_3^{(1)} = \mathbf{a}_3 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_3}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 \Rightarrow \bar{\mathbf{q}}_3 = \mathbf{a}_3^{(1)} - \frac{\bar{\mathbf{q}}_2^T \mathbf{a}_3^{(1)}}{\bar{\mathbf{q}}_2^T \bar{\mathbf{q}}_2} \bar{\mathbf{q}}_2 \Rightarrow \text{itd.}$$

$$\mathbf{a}_4^{(1)} = \mathbf{a}_4 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_4}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 \quad \mathbf{a}_4^{(2)} = \mathbf{a}_4^{(1)} - \frac{\bar{\mathbf{q}}_2^T \mathbf{a}_4^{(1)}}{\bar{\mathbf{q}}_2^T \bar{\mathbf{q}}_2} \bar{\mathbf{q}}_2$$

$$\mathbf{a}_5^{(1)} = \mathbf{a}_5 - \frac{\bar{\mathbf{q}}_1^T \mathbf{a}_5}{\bar{\mathbf{q}}_1^T \bar{\mathbf{q}}_1} \bar{\mathbf{q}}_1 \quad \mathbf{a}_5^{(2)} = \mathbf{a}_5^{(1)} - \frac{\bar{\mathbf{q}}_2^T \mathbf{a}_5^{(1)}}{\bar{\mathbf{q}}_2^T \bar{\mathbf{q}}_2} \bar{\mathbf{q}}_2$$
$$\vdots \quad \quad \quad \vdots$$

ZMODYFIKOWANY ALGORYTM Grama-Schmidta

Zmodyfikowany algorytm Grama-Schmidta (MGS) ortogonalizuje wobec ostatniej zortogonalizowanej kolumny wszystkie następne kolumny, w pseudonotacji Matlab:

```
for i = 1:n,
     $\bar{\mathbf{q}}_i = \mathbf{a}_i^{(i)}; \quad \bar{r}_{ii} = 1;$ 
     $d_i = \bar{\mathbf{q}}_i^T * \bar{\mathbf{q}}_i;$ 
    for j = i+1:n
         $\bar{r}_{ij} = (\bar{\mathbf{q}}_i^T * \mathbf{a}_j^{(i)}) / d_i;$ 
         $\mathbf{a}_j^{(i+1)} = \mathbf{a}_j^{(i)} - \bar{r}_{ij} * \bar{\mathbf{q}}_i;$ 
    end
end
```

Matematycznie, algorytmy CGS i MGS są równoważne, ale MGS ma lepsze własności numeryczne.

ROZKŁAD QR zmodyfikowanym algorytmem Grama-Schmidta


```
function [Q,R]=qrmgs(A)
%rozkład QR (wąski) zmodyfikowanym algorytmem Grama-Schmidta
%dla macierzy prostokątnych rzeczywistych i zespolonych
[m n]=size(A); Q=zeros(m,n); R=zeros(n,n); d=zeros(1,n);
    %rozkład z kolumnami Q ortogonalnymi (nie ortonormalnymi):
for i=1:n
    Q(:,i)=A(:,i);
    R(i,i)=1;
    d(i)=Q(:,i)'*Q(:,i);
    for j=i+1:n
        R(i,j)=(Q(:,i)'*A(:,j))/d(i);
        A(:,j)=A(:,j)-R(i,j)*Q(:,i);
    end
end
    %normowanie rozkładu (kolumny Q ortonormalne):
for i=1:n
    Q(:,i)=Q(:,i)/sqrt(d(i));
    R(i,i:n)=R(i,i:n)*sqrt(d(i));
end
```

WARTOŚCI WŁASNE

$\mathbf{A}_{n \times n}$: $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$, λ – wartość własna, \mathbf{v} – wektor własny

Macierz o wymiarze n ma dokładnie n wartości własnych: $\mathbf{A}\mathbf{v}_i = \lambda_i\mathbf{v}_i$, $i = 1, \dots, n$.

Interpretacja dla $n = 2$ i macierzy \mathbf{A} symetrycznej:




WARTOŚCI WŁASNE

$\mathbf{A}_{n \times n}$: $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$, λ – wartość własna, \mathbf{v} – wektor własny

Macierz o wymiarze n ma dokładnie n wartości własnych: $\mathbf{A}\mathbf{v}_i = \lambda_i\mathbf{v}_i$, $i = 1, \dots, n$.

Interpretacja dla $n = 2$ i macierzy \mathbf{A} symetrycznej:




$$\begin{aligned}\|\mathbf{A}\|_2 &= \max_{\|\mathbf{x}=1\|_2} \|\mathbf{A}\mathbf{x}\|_2 \\ &= \max_{\|\mathbf{x}=1\|_2} \sqrt{\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x}} = \sqrt{\max_{\|\mathbf{x}=1\|_2} \mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x}} = \sqrt{\mathbf{v}_{max}^T (\lambda_{max} \mathbf{v}_{max})} = \sqrt{\lambda_{max}}\end{aligned}$$

WARTOŚCI WŁASNE

$\mathbf{A}_{n \times n}$: $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$, λ – wartość własna, \mathbf{v} – wektor własny

Macierz o wymiarze n ma dokładnie n wartości własnych: $\mathbf{A}\mathbf{v}_i = \lambda_i\mathbf{v}_i$, $i = 1, \dots, n$.

Interpretacja dla $n = 2$ i macierzy \mathbf{A} symetrycznej – zbieżność/rozbieżność:



WARTOŚCI WŁASNE 2

$$\mathbf{A}_{n \times n} : \quad \mathbf{A}\mathbf{v} = \lambda\mathbf{v}, \quad \lambda - \text{wartość własna, } \mathbf{v} - \text{wektor własny}$$
$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v} \iff (\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0}$$

λ jest wartością własną macierzy \mathbf{A} wtedy i tylko wtedy, jeśli jest pierwiastkiem równania charakterystycznego:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0$$

$\text{sp}(\mathbf{A})$ – zbiór wszystkich wartości własnych macierzy \mathbf{A} (*spectrum*)

$$\lambda \in \text{sp}(\mathbf{A}) \Rightarrow \forall \alpha \in \mathbb{R} \quad (\lambda + \alpha) \in \text{sp}(\mathbf{A} + \alpha\mathbf{I})$$

Macierze \mathbf{A} i \mathbf{B} są podobne, jeśli istnieje macierz nieosobliwa \mathbf{S} taka, że

$$\mathbf{S}^{-1}\mathbf{A}\mathbf{S} = \mathbf{B}$$

Macierze podobne mają takie same wartości własne, gdyż:

$$\begin{aligned} \det(\mathbf{S}^{-1}\mathbf{A}\mathbf{S} - \lambda\mathbf{I}) &= \det(\mathbf{S}^{-1}\mathbf{A}\mathbf{S} - \lambda\mathbf{S}^{-1}\mathbf{S}) \\ &= \det \mathbf{S}^{-1}(\mathbf{A} - \lambda\mathbf{I})\mathbf{S} \\ &= \det \mathbf{S}^{-1} \det(\mathbf{A} - \lambda\mathbf{I}) \det \mathbf{S} \\ &= \det(\mathbf{A} - \lambda\mathbf{I}) \end{aligned}$$

WARTOŚCI WŁASNE 3

Twierdzenie. Jeśli macierz $\mathbf{A} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ jest **symetryczna**, to wszystkie wartości własne i wektory własne są **rzeczywiste**. Ponadto, **istnieje zbiór n ortonormalnych wektorów własnych** (istnieje zbiór wektorów własnych tworzący bazę ortonormalną przestrzeni \mathbb{R}^n).

Twierdzenie: Jeśli wszystkie wektory własne macierzy \mathbf{A}_n są ortogonalne (ortonormalne), to można tę macierz sprowadzić do postaci diagonalnej $\text{diag}\{\lambda_1, \dots, \lambda_n\}$, przez podobieństwo.

Dowód:

$$\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad i = 1, \dots, n, \quad \text{lub w zapisie macierzowym :}$$

$$\mathbf{A}\mathbf{V} = \mathbf{V}\text{diag}\{\lambda_i\}, \quad \text{gdzie } \mathbf{V} \triangleq [\mathbf{v}_1, \dots, \mathbf{v}_n]$$

$$\mathbf{V}^T \mathbf{A}\mathbf{V} = \mathbf{V}^T \mathbf{V} \text{diag}\{\lambda_i\}$$

Ponieważ macierz \mathbf{V} jest ortogonalna, to $\mathbf{V}^T \mathbf{V} = \mathbf{I}$, $\mathbf{V}^T = \mathbf{V}^{-1}$, skąd

$$\mathbf{V}^{-1} \mathbf{A}\mathbf{V} = \text{diag}\{\lambda_i\}.$$

Wniosek: Każdą macierz symetryczną \mathbf{A}_n można sprowadzić do macierzy diagonalnej $\text{diag}\{\lambda_1, \dots, \lambda_n\}$, przez podobieństwo.

WARTOŚCI WŁASNE 4

\mathbf{A}^* – transpozycja macierzy i sprzężenie elementów zespolonych: $\mathbf{A}^* = \bar{\mathbf{A}}^T$.

Macierz kwadratowa o elementach w ogólności zespolonych \mathbf{A} jest:

- *hermitowska*, gdy $\mathbf{A} = \mathbf{A}^*$,
- *unitarna*, gdy $\mathbf{A}^* \mathbf{A} = \mathbf{I}$ ($\Leftrightarrow \mathbf{A}^* = \mathbf{A}^{-1}$).

Jeśli macierz o elementach w ogólności zespolonych \mathbf{A}_n jest *normalna*, tzn.

$$\mathbf{A}^* \mathbf{A} = \mathbf{A} \mathbf{A}^* \quad (\mathbf{A}^T \mathbf{A} = \mathbf{A} \mathbf{A}^T),$$

to istnieje zbiór jej n ortonormalnych wektorów własnych (istnieje zbiór wektorów własnych tworzący bazę ortonormalną przestrzeni \mathbb{R}^n).

Twierdzenie (Schura). *Każda macierz* \mathbf{A}_n jest podobna do macierzy trójkątnej górnej (w ogólności zespolonej) \mathbf{R} ,

$$\mathbf{U}^{-1} \mathbf{A} \mathbf{U} = \begin{bmatrix} \lambda_1 & x & \cdots & x & x \\ 0 & \lambda_2 & \cdots & x & x \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & \cdots & 0 & \lambda_n \end{bmatrix} = \mathbf{R},$$

gdzie macierz przekształcenia \mathbf{U} jest macierzą unitarną.

WYBRANE METODY WYZNACZANIA WART. WŁASNYCH

- **Metody wyznacznikowe**, wykorzystujące fakt, że wartości własne są zerami wielomianu charakterystycznego $\det(\lambda \mathbf{I} - \mathbf{A}) = 0$ – efektywne dla pojedynczej czy niewielu wartości własnych.

Przykłady:

1. **Metoda bisekcji wykorzystująca ciągi Sturma** – dla macierzy symetrycznych. Pojedynczą wartość własną znajdujemy metodą bisekcji, decyzje o wyborze jednego z pododcinków po każdym podziale podejmuje się łatwo korzystając z pewnych własności tzw. wielomianów Sturma. Macierz wyjściową należy najpierw sprowadzić do *postaci trójdagonalnej* \mathbf{T} :

$$\mathbf{T} = \begin{bmatrix} x & x & 0 & 0 & \cdots & 0 & 0 \\ x & x & x & 0 & \cdots & 0 & 0 \\ 0 & x & x & x & \cdots & 0 & 0 \\ 0 & 0 & x & x & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & x & x \end{bmatrix}$$

WYBRANE METODY WYZNACZANIA WART. WŁASNYCH 2

2. **Metoda Hymana** – pierwiastki wielomianu charakterystycznego znajdujemy metodą Newtona, wykorzystując specyficzny sposób obliczania wartości wielomianu i jego pochodnej.
Macierz wyjściową zaleca się na wstępie sprowadzić do *postaci Hessenberga* (tzn. prawie trójkątnej górnej) :

$$\mathbf{H} = \begin{bmatrix} x & x & x & x & \cdots & x & x \\ x & x & x & x & \cdots & x & x \\ 0 & x & x & x & \cdots & x & x \\ 0 & 0 & x & x & \cdots & x & x \\ \vdots & \vdots & \vdots & \vdots & & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & x & x \end{bmatrix}$$

- **Metoda Jacobiego** – diagonalizacja macierzy symetrycznej za pomocą ciągu obrotów Givensa (efektywne do wymiaru $n \cong 10$).
- **Metoda QR** – najbardziej ogólna, efektywna.

WARTOŚCI WŁASNE – METODA QR

Metoda *iteracyjna*, opiera się na sukcesywnym wykorzystywaniu *rozkładu QR*.

Metoda QR dla macierzy symetrycznych:

Zalecane (niekonieczne) wstępne sprowadzenie \mathbf{A} do *postaci trójdagonalnej* (*postać Hessenberga macierzy symetrycznej*).

Schemat pojedynczej iteracji:

$$\begin{aligned}\mathbf{A}^{(k)} &= \mathbf{Q}^{(k)} \mathbf{R}^{(k)} \implies \mathbf{R}^{(k)} = \mathbf{Q}^{(k)T} \mathbf{A}^{(k)} \\ \mathbf{A}^{(k+1)} &= \mathbf{R}^{(k)} \mathbf{Q}^{(k)} = \mathbf{Q}^{(k)T} \mathbf{A}^{(k)} \mathbf{Q}^{(k)} \quad - \text{też trójdagonalna}\end{aligned}$$

Algorytm podstawowy:

$$\begin{aligned}\mathbf{A}^{(1)} &= \mathbf{A} \\ \mathbf{A}^{(1)} &= \mathbf{Q}^{(1)} \mathbf{R}^{(1)} \quad (\text{faktoryzacja}) \\ \mathbf{A}^{(2)} &= \mathbf{R}^{(1)} \mathbf{Q}^{(1)} \quad (= \mathbf{Q}^{(1)T} \mathbf{A}^{(1)} \mathbf{Q}^{(1)}) \\ \mathbf{A}^{(2)} &= \mathbf{Q}^{(2)} \mathbf{R}^{(2)} \quad (\text{faktoryzacja}) \\ \mathbf{A}^{(3)} &= \mathbf{R}^{(2)} \mathbf{Q}^{(2)} \quad (= \mathbf{Q}^{(2)T} \mathbf{A}^{(2)} \mathbf{Q}^{(2)} = \mathbf{Q}^{(2)T} \mathbf{Q}^{(1)T} \mathbf{A}^{(1)} \mathbf{Q}^{(1)} \mathbf{Q}^{(2)}) \\ &\text{itd.} \\ \mathbf{A}^{(k)} &\longrightarrow \mathbf{V}^{-1} \mathbf{A} \mathbf{V} = \text{diag} \{ \lambda_i \}\end{aligned}$$

WARTOŚCI WŁASNE – METODA QR 2

Jeśli $|\lambda_1| > |\lambda_2| > \dots > |\lambda_n| > 0$ (różne wartości własne)

to $a_{i+1,i}^{(k)} \rightarrow 0$ liniowo z ilorazem $\left| \frac{\lambda_{i+1}}{\lambda_i} \right|$,

czyli

$$\frac{a_{i+1,i}^{(k+1)}}{a_{i+1,i}^{(k)}} \approx \left| \frac{\lambda_{i+1}}{\lambda_i} \right|, \quad i = 1, \dots, n-1$$

Algorytm z przesunięciami (k -ta iteracja):

$$\begin{aligned} \mathbf{A}^{(k)} - p_k \mathbf{I} &= \mathbf{Q}^{(k)} \mathbf{R}^{(k)} \quad \implies \quad \mathbf{R}^{(k)} = \mathbf{Q}^{(k)T} (\mathbf{A}^{(k)} - p_k \mathbf{I}) \\ \mathbf{A}^{(k+1)} &= \mathbf{R}^{(k)} \mathbf{Q}^{(k)} + p_k \mathbf{I} \\ &= \mathbf{Q}^{(k)T} (\mathbf{A}^{(k)} - p_k \mathbf{I}) \mathbf{Q}^{(k)} + p_k \mathbf{I} \\ &= \mathbf{Q}^{(k)T} \mathbf{A}^{(k)} \mathbf{Q}^{(k)} \end{aligned}$$

Wówczas zbieżność:

$$\frac{a_{i+1,i}^{(k+1)}}{a_{i+1,i}^{(k)}} \approx \frac{|\lambda_{i+1} - p_k|}{|\lambda_i - p_k|}$$

.

Wybór p_k :

bliższa $d_n^{(k)}$ wartość własna zaznaczonej podmacierzy 2×2 macierzy $\mathbf{A}^{(k)}$,

$$\text{(tródiagonalna)} \mathbf{A}^{(k)} = \begin{bmatrix} d_1^{(k)} & \cdot & \cdot & \cdot & 0 \\ \cdot & \ddots & & & \\ \cdot & & d_{n-2}^{(k)} & e_{n-2}^{(k)} & 0 \\ \cdot & & e_{n-2}^{(k)} & \boxed{d_{n-1}^{(k)} \quad e_{n-1}^{(k)}} \\ 0 & \cdot & 0 & \boxed{e_{n-1}^{(k)} \quad d_n^{(k)}} \end{bmatrix}$$

Iterujemy z przesunięciami aż do $e_{n-1}^{(k)} = 0$

(dla macierzy pełnej do wyzerowania ostatniego wiersza oprócz $d_n^{(k)}$).

WARTOŚCI WŁASNE – METODA QR 4

Struktura algorytmu **QR** z przesunięciami:

1. Znajdujemy wartość własną λ_n w przedstawiony sposób,
2. Opuszczamy ostatni wiersz i ostatnią kolumnę aktualnej macierzy $(\mathbf{A})^k$ (deflacja), tzn. uwzględniamy dalej podmacierz $\mathbf{A}_{n-1}^{(k)}$,

$$\mathbf{A}^{(k)} = \begin{bmatrix} d_1^{(k)} & \cdot & \cdot & \cdot & 0 \\ \cdot & \ddots & & & \\ \cdot & & d_{n-2}^{(k)} & e_{n-2}^{(k)} & 0 \\ \cdot & & e_{n-2}^{(k)} & d_{n-1}^{(k)} & 0 \\ 0 & \cdot & 0 & 0 & \lambda_n^{(k)} \end{bmatrix} \Rightarrow \mathbf{A}_{n-1}^{(k)} = \begin{bmatrix} d_1^{(k)} & \cdot & \cdot & \cdot \\ \cdot & \ddots & & \\ \cdot & & d_{n-2}^{(k)} & e_{n-2}^{(k)} \\ \cdot & \cdot & e_{n-2}^{(k)} & d_{n-1}^{(k)} \end{bmatrix}$$

3. Znajdujemy λ_{n-1} , w analogiczny sposób - tzn. przekształcamy macierz trójdziagonalną $\mathbf{A}_{n-1}^{(k)}$ aż do uzyskania $e_{n-2}^{(k)} = 0$ (przy przekształcaniu macierzy pełnej aż do wyzerowania ostatniego wiersza prócz $d_{n-1}^{(k)}$).
4. Opuszczamy ostatni wiersz i ostatnią kolumnę macierzy $\mathbf{A}_{n-1}^{(k)}$ (deflacja),
itd. od punktu 2 do 4 dla wymiaru macierzy $n-2, n-3, \dots, 2$ – do znalezienia wszystkich wartości własnych.

WARTOŚCI WŁASNE – METODA QR 5

Metoda QR dla macierzy niesymetrycznych:

identyczna struktura, tylko należy stosować arytmetykę liczb zespolonych (metoda może zawieść).

Liczby iteracji algorytmów metody QR bez przesunięć i z przesunięciami:

tolerancja	tol=0.00001		tol=0.0000001		liczba zesp. wart. własnych
alg. z przesunięciami	nie	tak	nie	tak	
macierz symetryczna 5×5	35	7	47	8	0
	154	6	failed	23	0
	91	8	124	9	0
macierz symetryczna 10×10	93	16	129	16	0
	132	24	193	76	0
	failed	15	failed	18	0
macierz niesymetr. 5×5	–	7	–	8	2
	–	55	–	78	4
	–	10	–	11	2
macierz niesymetr. 10×10	–	24	–	27	6
	–	44	–	54	4
	–	26	–	45	4

WARTOŚCI SZCZEGÓLNE

Rozważamy macierz prostokątną $\mathbf{A}_{m \times n}$, $m \geq n$.

$(\mathbf{A}^T \mathbf{A})_{n \times n}$ jest zawsze symetryczna i dodatnio półokreślona, stąd

$$\forall \lambda \in \text{sp}(\mathbf{A}^T \mathbf{A}) \quad \lambda_i \geq 0$$

czyli istnieją pierwiastki λ_i :

$$\lambda_i = (\sigma_i)^2, \quad \sigma_i \geq 0, \quad i = 1, \dots, n$$

σ_i to **wartości szczególne** (*singularne*, *singular values*) macierzy \mathbf{A} .

Wnioski:

$\mathbf{A}_{n \times n}$ symetryczna i dodatnio półokreślona, to

$$\sigma_i = \lambda_i, \quad \lambda_i \in \text{sp}(\mathbf{A}), \quad i = 1, \dots, n$$

$\mathbf{A}_{n \times n}$ symetryczna, to

$$\sigma_i = |\lambda_i|, \quad \lambda_i \in \text{sp}(\mathbf{A}), \quad i = 1, \dots, n$$

WARTOŚCI SZCZEGÓLNE 2

Uwaga. Wyznaczanie σ_i poprzez wyznaczanie wartości własnych macierzy $\mathbf{A}^T \mathbf{A}$ prowadzi do **utraty dokładności**, przykład:

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ \varepsilon & 0 \\ 0 & \varepsilon \end{bmatrix}, \text{ gdzie } \varepsilon < \sqrt{\text{eps}}. \quad \text{Mamy } \mathbf{A}^T \mathbf{A} = \begin{bmatrix} 1 + \varepsilon^2 & 1 \\ 1 & 1 + \varepsilon^2 \end{bmatrix},$$

stąd wartości szczególne macierzy \mathbf{A} : $\sigma_1(\mathbf{A}) = \sqrt{2 + \varepsilon^2}$, $\sigma_2(\mathbf{A}) = |\varepsilon|$.

Natomiast

$$fl(\mathbf{A}^T \mathbf{A}) = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad (\text{gdyż } \varepsilon^2 < \text{eps}),$$

stąd wartości szczególne \mathbf{A} liczone numerycznie jako pierwiastki wartości własnych $\mathbf{A}^T \mathbf{A}$ w arytmetyce zmiennopozycyjnej wynoszą $\tilde{\sigma}_1 = \sqrt{2}$, $\tilde{\sigma}_2 = 0$.

Ale przecież $\sigma_2(\mathbf{A}) = |\varepsilon|$, co potwierdza **dużą utratę dokładności**,

np. dla $\text{eps} = 10^{-12}$ i $\varepsilon = 10^{-7}$ ($< \sqrt{\text{eps}} = 10^{-6}$) powinniśmy dostać $\sigma_2(\mathbf{A}) = 10^{-7}$ ($\gg \text{eps}$), a nie 0.

Stosuje się algorytmy SVD **nie prowadzące do utraty dokładności** (np. algorytm Goluba-Reinscha).

DEKOMPOZYCJA SVD

Twierdzenie (dekompozycja SVD).

Dla dowolnej macierzy $\mathbf{A}_{m \times n}$ istnieją macierze ortogonalne $\mathbf{U}_{m \times m}$, $\mathbf{V}_{n \times n}$ i macierz $\mathbf{\Sigma}_{m \times n}$ takie, że:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T, \quad \text{gdzie } \mathbf{\Sigma} = \begin{bmatrix} \mathbf{D}_{n \times n} \\ \mathbf{0}_{(m-n) \times n} \end{bmatrix}_{m \times n} = \begin{bmatrix} \sigma_1 & 0 & \cdots & & 0 \\ 0 & \ddots & & & \\ \vdots & & \sigma_k & & \vdots \\ & & & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_n & \\ \hline & & & & \mathbf{0} \end{bmatrix},$$

gdzie:

- $\mathbf{D}_{n \times n} = \text{diag}\{\sigma_i, i = 1, \dots, n\}$, $\sigma_i \geq 0$, zwyczajowo $\sigma_i \geq \sigma_{i+1}$. (Jeśli istnieją zerowe, to \mathbf{D} osobliwa, a \mathbf{A} niepełnego rzędu - ilość niezerowych σ_i to rząd $k \leq n$ macierzy \mathbf{A}),
- $\mathbf{U}_{m \times m}$ macierz, której kolumnami są ortonormalne wektory własne macierzy $\mathbf{A}\mathbf{A}^T$,
- $\mathbf{V}_{n \times n}$ macierz, której kolumnami są ortonormalne wektory własne macierzy $\mathbf{A}^T\mathbf{A}$.

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW LZNK

Dane: $\mathbf{A}_{m \times n}$, $(m > n, \text{rank } \mathbf{A} \leq n)$, $\mathbf{b} \in \mathbb{R}^m$.

Zadanie: znaleźć wektor $\hat{\mathbf{x}} \in \mathbb{R}^n$ taki, że

$$\forall \mathbf{x} \in \mathbb{R}^n \quad \|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\|_2 \leq \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2.$$

Interpretacja geometryczna: $\mathbf{A}\hat{\mathbf{x}}$ jest rzutem ortogonalnym wektora \mathbf{b} na podprzestrzeń rozpinaną przez kolumny macierzy \mathbf{A} (tzn. podprzestrzeń $\{\mathbf{y} \in \mathbb{R}^m : \mathbf{y} = \mathbf{A}\mathbf{x}, \mathbf{x} \in \mathbb{R}^n\}$).

Zadanie LZNK może mieć **niejednoznaczne rozwiązanie**, dla ujednoznacznienia wymaga się zwykle **wektora rozwiązania o najmniejszej normie**, tzn.

$$(\|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2 = \|\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}\|_2) \Rightarrow \|\hat{\mathbf{x}}\|_2 \leq \|\mathbf{x}\|_2$$

lub **wektora o największej liczbie zerowych składników**.

LNZK jest równoważne minimalizacji następującej funkcji kwadratowej $J(x)$:

$$J(x) = (\mathbf{b} - \mathbf{A}\mathbf{x})^T (\mathbf{b} - \mathbf{A}\mathbf{x}) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - 2\mathbf{x}^T \mathbf{A}^T \mathbf{b} + \mathbf{b}^T \mathbf{b}.$$

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW 2

Niech k – rząd macierzy \mathbf{A} , $k \leq n$.

Metody rozwiązywania LZNK:

a) *Macierz \mathbf{A} pełnego rzędu ($k = n$) :*

Jeśli $k = n$ to $\mathbf{A}^T \mathbf{A} > 0$, stąd funkcja $J(x) = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - 2\mathbf{x}^T \mathbf{A}^T \mathbf{b} + \mathbf{b}^T \mathbf{b}$ jest ściśle wypukła i ma jednoznaczne minimum w punkcie $J'(x) = 0$:

$$J'(x)^T = 2\mathbf{A}^T \mathbf{A} \mathbf{x} - 2\mathbf{A}^T \mathbf{b} = 0.$$

Wynikający stąd układ równań liniowych to *układ równań normalnych*:

$$\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b},$$

który ma jednoznaczne rozwiązanie.

Dla *słabo uwarunkowanej macierzy* \mathbf{A} uwarunkowanie $\mathbf{A}^T \mathbf{A}$ staje się jeszcze gorsze, gdyż

$$\text{cond}_2(\mathbf{A}^T \mathbf{A}) = (\text{cond}_2 \mathbf{A})^2 = \sigma_1^2 / \sigma_n^2,$$

gdzie σ_1 i σ_n to największa i najmniejsza wartość szczególna macierzy \mathbf{A} .

Wówczas zalecane jest skorzystanie z rozkładu **QR** macierzy \mathbf{A} .

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW 3

Wykorzystując wąski rozkład QR macierzy A , układ równań normalnych

$$A^T A x = A^T b$$

możemy zapisać w postaci

$$R^T Q^T Q R x = R^T Q^T b.$$

Q ma kolumny wzajemnie ortogonalne, tzn. $Q^T Q = I$, zaś R jest nieosobliwa (gdyż $k = n$), stąd dostajemy dobrze określony układ równań liniowych

$$R x = Q^T b.$$

Jeśli zastosujemy rozkład QR **wąski nieunormowany** (np. bezpośrednio z ortogonalizacji Grama-Schmidta), $A_{m \times n} = \bar{Q}_{m \times n} \bar{R}_{n \times n}$, to układ równań normalnych jest postaci:

$$\bar{R}^T \bar{Q}^T \bar{Q} \bar{R} x = \bar{R}^T \bar{Q}^T b,$$

skąd wynika

$$\bar{R} x = (\bar{Q}^T \bar{Q})^{-1} \bar{Q}^T b,$$

gdzie $\bar{Q}^T \bar{Q} = \text{diag}\{d_1, d_2, \dots, d_n\}$, $d_i = \bar{q}_i^T \bar{q}_i$, $i = 1, \dots, n$.

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW 4

b) *Jeśli $k < n$ (macierz \mathbf{A} niepełnego rzędu), to zalecany jest algorytm oparty na rozkładzie SVD macierzy \mathbf{A} .*

Stosując SVD i własność macierzy ortogonalnej $\|\mathbf{U}^T \mathbf{y}\|_2 = \|\mathbf{y}\|_2$ mamy:

$$\|\mathbf{b} - \mathbf{Ax}\|_2 = \|\mathbf{b} - \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \mathbf{x}\|_2 = \|\mathbf{U}^T \mathbf{b} - \mathbf{\Sigma} (\mathbf{V}^T \mathbf{x})\|_2 = \|\tilde{\mathbf{b}} - \mathbf{\Sigma}\tilde{\mathbf{x}}\|_2,$$

gdzie $\tilde{\mathbf{b}} = \mathbf{U}^T \mathbf{b}$, $\tilde{\mathbf{x}} = \mathbf{V}^T \mathbf{x}$.

Oznaczmy: $\tilde{\mathbf{b}} = [\tilde{\mathbf{b}}_1^T \ \tilde{\mathbf{b}}_2^T]^T$, $\tilde{\mathbf{b}}_1 \in \mathbb{R}^n$, $\tilde{\mathbf{b}}_2 \in \mathbb{R}^{m-n}$, stąd

$$\|\mathbf{b} - \mathbf{Ax}\|_2 = \|\tilde{\mathbf{b}} - \mathbf{\Sigma}\tilde{\mathbf{x}}\|_2 = \left\| \begin{array}{c} \tilde{\mathbf{b}}_1 - \mathbf{D}\tilde{\mathbf{x}} \\ \tilde{\mathbf{b}}_2 \end{array} \right\|_2 = \left\| \begin{array}{c} \tilde{b}_1 - \sigma_1 \tilde{x}_1 \\ \vdots \\ \tilde{b}_k - \sigma_k \tilde{x}_k \\ \tilde{b}_{k+1} \\ \vdots \\ \tilde{b}_m \end{array} \right\|_2,$$

gdzie $k \leq n$ to liczba niezerowych wartości szczególnych (rzęd macierzy \mathbf{A}).

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW 5

Norma $\|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$ osiąga minimum $\sqrt{\sum_{i=k+1}^m (\tilde{b}_i)^2}$ dla każdego $\tilde{\mathbf{x}}$ postaci:

$$\tilde{\mathbf{x}} = \begin{bmatrix} \tilde{x}_1 = \tilde{b}_1/\sigma_1 \\ \vdots \\ \tilde{x}_k = \tilde{b}_k/\sigma_k \\ \tilde{x}_{k+1} \text{ dowolne} \\ \vdots \\ \tilde{x}_n \text{ dowolne} \end{bmatrix}$$

Rozwiązanie jednoznaczne $\hat{\tilde{\mathbf{x}}}$ o minimalnej normie uzyskujemy przyjmując

$$\hat{\tilde{\mathbf{x}}} = \begin{bmatrix} \tilde{b}_1/\sigma_1 \\ \vdots \\ \tilde{b}_k/\sigma_k \\ 0 \\ \vdots \\ 0 \end{bmatrix},$$

$$\text{tzn. } \hat{\tilde{\mathbf{x}}} = \mathbf{\Sigma}^+ \tilde{\mathbf{b}}, \quad \mathbf{\Sigma}^+ = [\mathbf{D}_{n \times n}^+ \quad \mathbf{0}_{n \times (m-n)}], \quad \mathbf{D}^+ = \text{diag}\left\{\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_k}, 0, \dots, 0\right\}$$

$$\text{Stąd} \quad \mathbf{V}^T \hat{\tilde{\mathbf{x}}} = \mathbf{\Sigma}^+ \mathbf{U}^T \mathbf{b} \quad \Rightarrow \quad \hat{\mathbf{x}} = \mathbf{V} \mathbf{\Sigma}^+ \mathbf{U}^T \mathbf{b},$$

$$\mathbf{A}^+ = \mathbf{V} \mathbf{\Sigma}^+ \mathbf{U}^T - \text{macierz pseudoodwrotna macierzy } \mathbf{A}$$

LINIOWE ZADANIE NAJMNIEJSZYCH KWADRATÓW – Przykład

Rozwiązać układ równań $\mathbf{Ax} = \mathbf{b}$, w sensie minimalizacji sumy kwadratów reszt, gdzie

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -1 \\ -2 & 4 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}.$$

Macierz \mathbf{A} jest pełnego rzędu, stąd można rozwiązać układ równań normalnych lub skorzystać z rozkładu QR.

Układ równań normalnych:

$$\mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b} \Leftrightarrow \begin{bmatrix} 9 & -9 \\ -9 & 18 \end{bmatrix} \mathbf{x} = \begin{bmatrix} 3 \\ 6 \end{bmatrix},$$

skąd rozwiązanie $\mathbf{x} = [\frac{4}{3}, 1]^T$.

Do rozwiązania metodą rozkładu QR wystarczy rozkład wąski, rozkład taki dla podanej macierzy \mathbf{A} wyliczyliśmy uprzednio w przykładzie, stąd

$$\mathbf{Rx} = \mathbf{Q}^T \mathbf{b} \Leftrightarrow \begin{bmatrix} 3 & -3 \\ 0 & 3 \end{bmatrix} \mathbf{x} = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} & -\frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} & \frac{2}{3} \end{bmatrix} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}$$

PRZEKSZTAŁCENIE (ODBICIE) HOUSEHOLDERA*

Przekształcenie zdefiniowane macierzą \mathbf{P} postaci

$$\mathbf{P} = \mathbf{I} - 2\mathbf{w}\mathbf{w}^T, \quad \text{gdzie } \mathbf{w} \in \mathbb{R}^n, \quad \|\mathbf{w}\| = 1.$$

Własności: $\mathbf{P} = \mathbf{P}^T$ (symetria),


$$\mathbf{P}\mathbf{P}^T = \mathbf{I} \quad (\text{tzn. } \mathbf{P} = \mathbf{P}^{-1}, \text{ ortogonalność}),$$

gdyż

$$(\mathbf{I} - 2\mathbf{w}\mathbf{w}^T)(\mathbf{I} - 2\mathbf{w}\mathbf{w}^T) = \mathbf{I} - 4\mathbf{w}\mathbf{w}^T + 4\mathbf{w}(\mathbf{w}^T\mathbf{w})\mathbf{w}^T = \mathbf{I}$$

Interpretacja geometryczna:

$$\mathbf{y} = \mathbf{P}\mathbf{a} = (\mathbf{I} - 2\mathbf{w}\mathbf{w}^T)\mathbf{a} = \mathbf{a} - 2(\mathbf{w}^T\mathbf{a})\mathbf{w} = \mathbf{a} - 2\mathbf{r},$$



$\mathbf{P}\mathbf{a}$ jest odbiciem zwierciadlanym \mathbf{a} względem płaszczyzny prostopadłej do \mathbf{w} .
Odpowiednio dobierając \mathbf{w} uzyskujemy dowolne położenie wektora $\mathbf{y} = \mathbf{P}\mathbf{a}$.

* materiał uzupełniający

PRZEKSZTAŁCENIE HOUSEHOLDERA - zastosowanie

Zadanie: uzyskanie $\mathbf{P}\mathbf{a} \parallel \mathbf{e}_1$, gdzie $\mathbf{e}_1 = [1 \ 0 \ 0 \ \dots \ 0]^T$.

Przyjmujemy $\mathbf{P} = \mathbf{I} - \frac{1}{K}\mathbf{u}\mathbf{u}^T$, $\mathbf{u} = \mathbf{a} \pm \|\mathbf{a}\| \mathbf{e}_1$, $K = \frac{1}{2} \|\mathbf{u}\|^2$, ($\mathbf{w} = \sqrt{2/K}\mathbf{u}$)

gdzie znak dobieramy tak, aby uzyskać większą normę \mathbf{u} , tzn.

$$\mathbf{u} = \mathbf{a} + \text{sgn}(a_1) \|\mathbf{a}\| \mathbf{e}_1, \quad \text{gdzie } a_1 = (\mathbf{e}_1)^T \mathbf{a}.$$

Wówczas:

$$\begin{aligned} \mathbf{P}\mathbf{a} &= \mathbf{a} - \frac{\mathbf{u}}{K} (\mathbf{a} + \text{sgn}(a_1) \|\mathbf{a}\| \mathbf{e}_1)^T \mathbf{a} \\ &= \mathbf{a} - \frac{2\mathbf{u} \left(\|\mathbf{a}\|^2 + \|\mathbf{a}\| |a_1| \right)}{\|\mathbf{a} + \text{sgn}(a_1) \|\mathbf{a}\| \mathbf{e}_1\|^2} \\ &= \mathbf{a} - \frac{2\mathbf{u} \left(\|\mathbf{a}\|^2 + \|\mathbf{a}\| |a_1| \right)}{\|\mathbf{a}\|^2 + \|\mathbf{a}\|^2 + 2 \|\mathbf{a}\| |a_1|} \\ &= \mathbf{a} - \mathbf{u} = -\text{sgn}(a_1) \|\mathbf{a}\| \mathbf{e}_1 \end{aligned}$$

Nie należy liczyć \mathbf{P} , tylko wynik $\mathbf{P}\mathbf{a}$: $\mathbf{P} = (\mathbf{I} - 2\mathbf{w}\mathbf{w}^T)\mathbf{a} = \mathbf{a} - (2\mathbf{w}^T \mathbf{a})\mathbf{w}$.

Przekształcenie Householdera jest algorytmem numerycznie poprawnym.