

Metody Probabilistyczne i Statystyka - wykład 9.

Charakterystyki liczbowe dwuwymiarowych zmiennych losowych

Analiza korelacji

6 maja 2025

Założenie:

Niech $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ będzie funkcją taką, że $g(X, Y)$ jest zmienną losową jednowymiarową.

Twierdzenie

Jeśli (X, Y) ma rozkład dyskretny, to

$$E(g(X, Y)) = \sum_{(x,y) \in S_{XY}} g(x, y) \cdot P(X = x, Y = y).$$

Twierdzenie

Jeśli (X, Y) ma rozkład dyskretny, to

$$E(g(X, Y)) = \sum_{(x,y) \in S_{XY}} g(x, y) \cdot P(X = x, Y = y).$$

W szczególności:

$$EX = \sum_{(x,y) \in S_{XY}} x \cdot P(X = x, Y = y)$$

Twierdzenie

Jeśli (X, Y) ma rozkład dyskretny, to

$$E(g(X, Y)) = \sum_{(x,y) \in S_{XY}} g(x, y) \cdot P(X = x, Y = y).$$

W szczególności:

$$EX = \sum_{(x,y) \in S_{XY}} x \cdot P(X = x, Y = y)$$

$$EY = \sum_{(x,y) \in S_{XY}} y \cdot P(X = x, Y = y)$$

Twierdzenie

Jeśli (X, Y) ma rozkład dyskretny, to

$$E(g(X, Y)) = \sum_{(x,y) \in S_{XY}} g(x, y) \cdot P(X = x, Y = y).$$

W szczególności:

$$EX = \sum_{(x,y) \in S_{XY}} x \cdot P(X = x, Y = y)$$

$$EY = \sum_{(x,y) \in S_{XY}} y \cdot P(X = x, Y = y)$$

$$E(XY) = \sum_{(x,y) \in S_{XY}} x \cdot y \cdot P(X = x, Y = y).$$

Przykład 1.

Wektor (X, Y) ma rozkład dyskretny o funkcji prawdopodobieństwa

$X \setminus Y$	-1	0	1	2
1	0.1	0.2	0	0.1
2	0.1	0	0.3	0.2

Obliczyć EX , EY , $E(XY)$.

Twierdzenie

Jeśli (X, Y) ma rozkład ciągły, to

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f_{XY}(x, y) dx dy.$$

Twierdzenie

Jeśli (X, Y) ma rozkład ciągły, to

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f_{XY}(x, y) dx dy.$$

W szczególności:

$$EX = \iint_{\mathbb{R}^2} x \cdot f_{XY}(x, y) dx dy$$

Twierdzenie

Jeśli (X, Y) ma rozkład ciągły, to

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f_{XY}(x, y) dx dy.$$

W szczególności:

$$EX = \iint_{\mathbb{R}^2} x \cdot f_{XY}(x, y) dx dy$$

$$EY = \iint_{\mathbb{R}^2} y \cdot f_{XY}(x, y) dx dy$$

Twierdzenie

Jeśli (X, Y) ma rozkład ciągły, to

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f_{XY}(x, y) dx dy.$$

W szczególności:


$$EX = \iint_{\mathbb{R}^2} x \cdot f_{XY}(x, y) dx dy$$

$$EY = \iint_{\mathbb{R}^2} y \cdot f_{XY}(x, y) dx dy$$

$$E(XY) = \iint_{\mathbb{R}^2} x \cdot y \cdot f_{XY}(x, y) dx dy.$$

Przykład 2.

Wektor (X, Y) ma rozkład jednostajny w prostokącie $D = [0; 6] \times [0; 2]$. Wyznaczyć EX , EY , $E(XY)$.



Uwagi:

- Punkt o współrzędnych (EX, EY) jest środkiem ciężkości nośnika rozkładu łącznego zmiennej losowej (X, Y) .

Uwagi:


- Punkt o współrzędnych (EX, EY) jest środkiem ciężkości nośnika rozkładu łącznego zmiennej losowej (X, Y) .
- Jeśli X i Y są niezależnymi zmiennymi losowymi, to

$$E(X \cdot Y) = EX \cdot EY.$$

Przykład 3.

Wektor (X, Y) ma rozkład jednostajny w trójkącie D o wierzchołkach $(0, 0)$, $(1, 0)$, $(0, 1)$.

$$f_{XY}(x, y) = 2 \cdot 1_D(x, y).$$



Sprawdzić, czy $E(XY) = EX \cdot EY$.







Analiza korelacji -




Analiza korelacji - badanie istnienia i siły liniowego związku między cechami populacji (zmiennymi losowymi).







Analiza korelacji




Analiza korelacji






- **Korelacja dodatnia** - wzrostowi (spadkowi) wartości jednej cechy towarzyszy wzrost (spadek) wartości drugiej cechy



- **Korelacja ujemna** - wzrostowi (spadkowi) wartości jednej cechy towarzyszy spadek (wzrost) wartości drugiej cechy




- **Korelacja zerowa** - brak korelacji (cechy są **nieskorelowane**).

Korelacja nie oznacza przyczynowości:

Korelacja nie oznacza przyczynowości: fakt, że dwie cechy są ze sobą skorelowane, nie musi oznaczać, że jedna jest przyczyną drugiej.

Korelacja

Korelacja nie oznacza przyczynowości: fakt, że dwie cechy są ze sobą skorelowane, nie musi oznaczać, że jedna jest przyczyną drugiej.



Kowariancja i współczynnik korelacji

Definicja

Kowariancją zmiennych losowych X i Y , dla których istnieją EX , EY , $E(XY)$, nazywamy liczbę

$$\text{cov}(X, Y) = E[(X - EX)(Y - EY)].$$

Kowariancja i współczynnik korelacji

Definicja

Kowariancją zmiennych losowych X i Y , dla których istnieją EX , EY , $E(XY)$, nazywamy liczbę

$$\text{cov}(X, Y) = E[(X - EX)(Y - EY)].$$

Uwaga

Miernikiem liniowej zależności między X i Y jest współczynnik korelacji.

Kowariancja i współczynnik korelacji

Definicja

Kowariancją zmiennych losowych X i Y , dla których istnieją EX , EY , $E(XY)$, nazywamy liczbę

$$\text{cov}(X, Y) = E[(X - EX)(Y - EY)].$$

Uwaga

Miernikiem liniowej zależności między X i Y jest współczynnik korelacji.

Definicja

Niech X i Y będą zmiennymi losowymi takimi, że $VX > 0$ i $VY > 0$.

Kowariancja i współczynnik korelacji

Definicja

Kowariancją zmiennych losowych X i Y , dla których istnieją EX , EY , $E(XY)$, nazywamy liczbę

$$\text{cov}(X, Y) = E[(X - EX)(Y - EY)].$$

Uwaga

Miernikiem liniowej zależności między X i Y jest współczynnik korelacji.

Definicja

Niech X i Y będą zmiennymi losowymi takimi, że $VX > 0$ i $VY > 0$. **Współczynnikiem korelacji** zmiennych X i Y nazywamy liczbę

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{VX \cdot VY}}.$$

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $$\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$$

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

$$\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) =$$

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

$$\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) = \sum_{k=1}^n (x_k - \bar{x}) \cdot y_k =$$

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

$$\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) = \sum_{k=1}^n (x_k - \bar{x}) \cdot y_k = \sum_{k=1}^n (y_k - \bar{y}) \cdot x_k,$$

gdzie

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

$$\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) = \sum_{k=1}^n (x_k - \bar{x}) \cdot y_k = \sum_{k=1}^n (y_k - \bar{y}) \cdot x_k,$$

gdzie

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k,$$

Kowariancja i współczynnik korelacji dla próby losowej

Jeśli dysponujemy próbą n -elementową $(x_1, y_1), \dots, (x_n, y_n)$, to:

- $\text{cov}(X, Y) = \frac{1}{n-1} \cdot \sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})$
- Współczynnik korelacji (**współczynnik korelacji próbkowej Pearsona**) obliczamy zgodnie ze wzorem:

$$r(X, Y) = \frac{\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y})}{\sqrt{\sum_{k=1}^n (x_k - \bar{x})^2 \cdot \sum_{k=1}^n (y_k - \bar{y})^2}},$$

przy czym

$$\sum_{k=1}^n (x_k - \bar{x})(y_k - \bar{y}) = \sum_{k=1}^n (x_k - \bar{x}) \cdot y_k = \sum_{k=1}^n (y_k - \bar{y}) \cdot x_k,$$

gdzie

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k, \quad \bar{y} = \frac{1}{n} \sum_{k=1}^n y_k.$$

- **Dodatnia korelacja między cechami X i Y :**
 $\text{cov}(X, Y) > 0, \rho(X, Y) > 0$

- **Dodatnia korelacja między cechami X i Y :**
 $\text{cov}(X, Y) > 0, \rho(X, Y) > 0$
- **Ujemna korelacja między cechami X i Y :**
 $\text{cov}(X, Y) < 0, \rho(X, Y) < 0$

- **Dodatnia korelacja między cechami X i Y :**
 $cov(X, Y) > 0, \rho(X, Y) > 0$
- **Ujemna korelacja między cechami X i Y :**
 $cov(X, Y) < 0, \rho(X, Y) < 0$
- **Cechy X i Y nieskorelowane:** $cov(X, Y) = 0, \rho(X, Y) = 0$

Własności współczynnika korelacji

- $|\rho(X, Y)| \leq 1$;

Własności współczynnika korelacji

- $|\rho(X, Y)| \leq 1$;
- $|\rho(X, Y)| = 1 \iff$ istnieją $a, b \in \mathbb{R}$ takie, że $Y = aX + b$

Własności współczynnika korelacji

- $|\rho(X, Y)| \leq 1$;
- $|\rho(X, Y)| = 1 \iff$ istnieją $a, b \in \mathbb{R}$ takie, że $Y = aX + b$
- X i Y są nieskorelowane $\iff \rho(X, Y) = 0$.

Własności współczynnika korelacji c.d.

Jeśli:

- $0 < |\rho(X, Y)| < 0.25$, to korelacja jest **bardzo słaba (pomijalna)**

Własności współczynnika korelacji c.d.

Jeśli:

- $0 < |\rho(X, Y)| < 0.25$, to korelacja jest **bardzo słaba (pomijalna)**
- $0.25 \leq |\rho(X, Y)| < 0.5$, to korelacja jest **słaba**

Własności współczynnika korelacji c.d.

Jeśli:

- $0 < |\rho(X, Y)| < 0.25$, to korelacja jest **bardzo słaba (pomijalna)**
- $0.25 \leq |\rho(X, Y)| < 0.5$, to korelacja jest **słaba**
- $0.5 \leq |\rho(X, Y)| < 0.75$, to korelacja jest **umiarkowana**

Własności współczynnika korelacji c.d.

Jeśli:

- $0 < |\rho(X, Y)| < 0.25$, to korelacja jest **bardzo słaba (pomijalna)**
- $0.25 \leq |\rho(X, Y)| < 0.5$, to korelacja jest **słaba**
- $0.5 \leq |\rho(X, Y)| < 0.75$, to korelacja jest **umiarkowana**
- $0.75 \leq |\rho(X, Y)| < 1$, to korelacja jest **silna**

Własności współczynnika korelacji c.d.

Jeśli:

- $0 < |\rho(X, Y)| < 0.25$, to korelacja jest **bardzo słaba (pomijalna)**
- $0.25 \leq |\rho(X, Y)| < 0.5$, to korelacja jest **słaba**
- $0.5 \leq |\rho(X, Y)| < 0.75$, to korelacja jest **umiarkowana**
- $0.75 \leq |\rho(X, Y)| < 1$, to korelacja jest **silna**
- $|\rho(X, Y)| = 1$, to korelacja jest **pełna**.

Uwaga

Jeśli zmienne losowe X i Y są niezależne, to $\text{cov}(X, Y) = 0$.

Uwaga

Jeśli zmienne losowe X i Y są niezależne, to $\text{cov}(X, Y) = 0$.
Ale: z tego, że X i Y są nieskorelowane nie wynika, że są niezależne!

Uwaga

Jeśli zmienne losowe X i Y są niezależne, to $\text{cov}(X, Y) = 0$.
Ale: z tego, że X i Y są nieskorelowane nie wynika, że są niezależne!

Wyjątkiem jest rozkład normalny:

**Jeśli (X, Y) ma rozkład normalny, to X i Y są niezależne \longleftrightarrow
 $\text{cov}(X, Y) = 0$.**

Twierdzenie

$$\text{cov}(X, Y) = E(X \cdot Y) - EX \cdot EY.$$

Własności kowariancji

❶ $\text{cov}(X, Y) = \text{cov}(Y, X)$

Własności kowariancji

- ① $\text{cov}(X, Y) = \text{cov}(Y, X)$
- ② $\text{cov}(X, X) = V_X$

Własności kowariancji

- ① $\text{cov}(X, Y) = \text{cov}(Y, X)$
- ② $\text{cov}(X, X) = VX$
- ③ $\text{cov}(a, X) = 0$ dla $a \in \mathbb{R}$

Własności kowariancji

- ① $\text{cov}(X, Y) = \text{cov}(Y, X)$
- ② $\text{cov}(X, X) = V_X$
- ③ $\text{cov}(a, X) = 0$ dla $a \in \mathbb{R}$
- ④ $\text{cov}(aX + b, cY + d) = a \cdot c \cdot \text{cov}(X, Y)$ dla $a, b, c, d \in \mathbb{R}$

Własności kowariancji

- ❶ $\text{cov}(X, Y) = \text{cov}(Y, X)$
- ❷ $\text{cov}(X, X) = VX$
- ❸ $\text{cov}(a, X) = 0$ dla $a \in \mathbb{R}$
- ❹ $\text{cov}(aX + b, cY + d) = a \cdot c \cdot \text{cov}(X, Y)$ dla $a, b, c, d \in \mathbb{R}$
- ❺

$$\begin{aligned} & \text{cov}(aX_1 + bX_2, cY_1 + dY_2) = \\ &= a \cdot c \cdot \text{cov}(X_1, Y_1) + a \cdot d \cdot \text{cov}(X_1, Y_2) + \\ &+ b \cdot c \cdot \text{cov}(X_2, Y_1) + b \cdot d \cdot \text{cov}(X_2, Y_2) \end{aligned}$$

Wariancja sumy i różnicy zmiennych losowych

Twierdzenie

Jeśli X i Y są zmiennymi losowymi, dla których istnieją wariancje, to

$$V(X + Y) = VX + 2cov(X, Y) + VY$$

$$V(X - Y) = VX - 2cov(X, Y) + VY.$$

Wariancja sumy i różnicy zmiennych losowych

Twierdzenie

Jeśli X i Y są zmiennymi losowymi, dla których istnieją wariancje, to

$$V(X + Y) = VX + 2cov(X, Y) + VY$$

$$V(X - Y) = VX - 2cov(X, Y) + VY.$$

Wniosek

Jeśli X i Y są nieskorelowane, to

$$V(X + Y) = V(X - Y) = VX + VY.$$